

# 均值-方差投资组合的多目标规划： 矩阵算法、解析解与投影梯度下降

矩阵算法课程项目

2026 年 6 月 12 日

## 摘要

本项目把量化金融中最经典的资产配置问题——Markowitz 均值-方差模型——建模为一个 **双目标规划问题**（同时最大化期望收益、最小化风险），并从**矩阵算法**的视角给出完整推导与实现。我们：(1) 用拉格朗日乘子法与 KKT 条件导出允许卖空时有效前沿的 **闭式解**，核心是对对称正定协方差矩阵  $\Sigma$  的求逆/求解（Cholesky 分解）；(2) 在加入不可卖空约束  $w \geq 0$  后问题失去闭式解，于是**从零实现投影梯度下降**（含单纯形欧氏投影的 KKT 推导与收敛性分析）；(3) 用 Ledoit-Wolf 收缩估计这一 **统计学习（机器学习）** 方法改善  $\Sigma$  的估计，并定量展示其在小样本/高维时的价值。全部结论在合成但统计特征真实的 8 资产数据上验证，并附 5 张图像。

## 目录

|     |                           |   |
|-----|---------------------------|---|
| 1   | 问题背景与现实意义                 | 2 |
| 2   | 多目标规划建模                   | 2 |
| 2.1 | 符号与假设                     | 2 |
| 2.2 | 双目标模型                     | 3 |
| 2.3 | 标量化：把多目标化为单目标             | 3 |
| 3   | 解析解：拉格朗日乘子与 KKT 条件        | 3 |
| 3.1 | 一阶最优性条件                   | 3 |
| 3.2 | 消去乘子：一个 $2 \times 2$ 线性系统 | 4 |
| 3.3 | 有效前沿的闭式表达                 | 4 |
| 3.4 | 两个关键组合                    | 4 |
| 4   | 矩阵算法要点                    | 5 |
| 4.1 | 用 Cholesky 分解求解，而非显式求逆    | 5 |
| 4.2 | 特征分解与条件数                  | 5 |

|                                                 |    |
|-------------------------------------------------|----|
| 1 问题背景与现实意义                                     | 2  |
| 4.3 正定性 $\Leftrightarrow$ 凸性 $\Rightarrow$ 全局最优 | 5  |
| 5 数值解：投影梯度下降                                    | 5  |
| 5.1 为什么需要数值法                                    | 5  |
| 5.2 投影梯度下降 (PGD)                                | 5  |
| 5.3 单纯形欧氏投影的推导                                  | 6  |
| 5.4 收敛性分析                                       | 6  |
| 6 机器学习联系：协方差矩阵的收缩估计                             | 6  |
| 7 实验与结果                                         | 7  |
| 8 随机矩阵理论与自助法推断 (样本外实验补充)                        | 10 |
| 8.1 Marcenko–Pastur 定理与特征值裁剪                    | 10 |
| 8.2 Circular block bootstrap 与夏普差检验             | 10 |
| 9 给期望收益开药方、维数相变与最优协方差                           | 11 |
| 9.1 Jorion 的 Bayes–Stein 收缩                     | 11 |
| 9.2 Black–Litterman 均衡先验与”无观点定理”                | 11 |
| 9.3 维数相变：RMT 的翻案                                | 11 |
| 9.4 最优协方差：解析非线性收缩                               | 12 |
| 10 结论                                           | 12 |

## 1 问题背景与现实意义

设某投资者面对  $n$  只股票，需决定把资金按比例  $\mathbf{w} = (w_1, \dots, w_n)^\top$  配置到各资产上 ( $w_i$  为第  $i$  只股票的权重,  $\sum_i w_i = 1$ )。投资者的两个目标天然冲突：

- **收益越高越好**：组合期望收益为  $\boldsymbol{\mu}^\top \mathbf{w}$ ，其中  $\boldsymbol{\mu} \in \mathbb{R}^n$  是各资产期望收益；
- **风险越低越好**：组合方差为  $\mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w}$ ，其中  $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$  是收益的协方差矩阵。

高收益资产往往伴随高波动，因此不存在同时让两者最优的单一解，而是一族**折中 (Pareto) 解**。寻找这族解、并理解“多承担一单位风险能换来多少额外收益”，正是资产配置的核心，也是一个标准的**多目标规划**问题。其数学骨架完全由矩阵运算构成（二次型、矩阵求逆、特征分解），因此非常适合作为矩阵算法课程的综合案例。

## 2 多目标规划建模

### 2.1 符号与假设

记全 1 向量为  $\mathbf{1} \in \mathbb{R}^n$ 。假设  $\Sigma$  **对称正定** ( $\Sigma \succ 0$ ) ——这在样本协方差中当观测期数  $T > n$  且无完全共线资产时几乎必然成立，也保证了二次型  $\mathbf{w}^\top \Sigma \mathbf{w} > 0$  (任意非零组合都有正风险) 以及目标函数的**严格凸性**。

### 2.2 双目标模型

$$\min_{\mathbf{w}} \left( \mathbf{w}^\top \Sigma \mathbf{w}, -\boldsymbol{\mu}^\top \mathbf{w} \right) \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1, \quad (\text{可选}) \quad \mathbf{w} \geq \mathbf{0}. \quad (1)$$

约束  $\mathbf{1}^\top \mathbf{w} = 1$  表示资金全部投出； $\mathbf{w} \geq \mathbf{0}$  表示**不可卖空** (只能买入)。

**定义 1** (Pareto 最优). 可行解  $\mathbf{w}^*$  称为 Pareto 最优, 若不存在另一可行解  $\mathbf{w}$  使得两个目标都不更差、且至少一个严格更优。所有 Pareto 最优组合在  $(\sigma, r) = (\sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}, \boldsymbol{\mu}^\top \mathbf{w})$  平面上的像称为**有效前沿** (efficient frontier)。

### 2.3 标量化：把多目标化为单目标

求解多目标规划的常用手段是**标量化**, 即用一个标量参数把两目标合成一个目标, 扫描该参数即可得到整条前沿。本文用两种等价方式：

(a) **加权和法**。 引入风险偏好系数  $\lambda \geq 0$ ：

$$\min_{\mathbf{w}} \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}^\top \mathbf{w} \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1. \quad (2)$$

$\lambda = 0$  对应纯最小方差； $\lambda \rightarrow \infty$  对应纯最大收益。

(b)  **$\varepsilon$ -约束法**。 固定一个目标收益  $r$ , 最小化风险：

$$\min_{\mathbf{w}} \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} \quad \text{s.t.} \quad \boldsymbol{\mu}^\top \mathbf{w} = r, \quad \mathbf{1}^\top \mathbf{w} = 1. \quad (3)$$

扫描  $r$  即得前沿。由于  $\Sigma \succ 0$  使目标严格凸、约束为线性，两种标量化都给出**唯一全局最优**，且其解集相同 (KKT 充要)。下一节用 (3) 推导闭式解。

## 3 解析解：拉格朗日乘子与 KKT 条件

### 3.1 一阶最优性条件

对 (3) 写拉格朗日函数 ( $\lambda, \gamma$  为乘子)：

$$\mathcal{L}(\mathbf{w}, \lambda, \gamma) = \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} - \lambda(\boldsymbol{\mu}^\top \mathbf{w} - r) - \gamma(\mathbf{1}^\top \mathbf{w} - 1). \quad (4)$$

对  $\mathbf{w}$  求梯度并令其为零（这就是等式约束下的 KKT 平稳性条件）：

$$\nabla_{\mathbf{w}} \mathcal{L} = \Sigma \mathbf{w} - \lambda \boldsymbol{\mu} - \gamma \mathbf{1} = \mathbf{0} \implies \boxed{\mathbf{w} = \Sigma^{-1}(\lambda \boldsymbol{\mu} + \gamma \mathbf{1})}. \quad (5)$$

因目标严格凸、约束线性，该平稳点即**全局最优**。

### 3.2 消去乘子：一个 $2 \times 2$ 线性系统

把 (5) 代入两个约束，并定义四个由矩阵  $\Sigma$  决定的标量

$$A = \mathbf{1}^T \Sigma^{-1} \boldsymbol{\mu}, \quad B = \boldsymbol{\mu}^T \Sigma^{-1} \boldsymbol{\mu}, \quad C = \mathbf{1}^T \Sigma^{-1} \mathbf{1}, \quad D = BC - A^2, \quad (6)$$

得到

$$\begin{cases} \boldsymbol{\mu}^T \mathbf{w} = \lambda B + \gamma A = r, \\ \mathbf{1}^T \mathbf{w} = \lambda A + \gamma C = 1, \end{cases} \iff \begin{bmatrix} B & A \\ A & C \end{bmatrix} \begin{bmatrix} \lambda \\ \gamma \end{bmatrix} = \begin{bmatrix} r \\ 1 \end{bmatrix}. \quad (7)$$

该系数矩阵的行列式恰为  $D = BC - A^2$ 。由 Cauchy-Schwarz 不等式（在内积  $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \Sigma^{-1} \mathbf{y}$  下）可证  $D > 0$ （当  $\boldsymbol{\mu}$  与  $\mathbf{1}$  线性无关），故系统可解：

$$\lambda = \frac{Cr - A}{D}, \quad \gamma = \frac{B - Ar}{D}. \quad (8)$$

### 3.3 有效前沿的闭式表达

最优组合的方差可由 (5) 巧妙化简（利用  $\mathbf{w}^T \Sigma \mathbf{w} = \mathbf{w}^T (\lambda \boldsymbol{\mu} + \gamma \mathbf{1}) = \lambda r + \gamma$ ）：

$$\boxed{\sigma^2(r) = \mathbf{w}^T \Sigma \mathbf{w} = \frac{Cr^2 - 2Ar + B}{D}}. \quad (9)$$

这是  $(\sigma^2, r)$  平面上的**抛物线**、 $(\sigma, r)$  平面上的**双曲线**——即图1 中的有效前沿。其顶点（最小方差点）由  $d\sigma^2/dr = 0$  给出。

### 3.4 两个关键组合

**命题 1** (全局最小方差组合 GMV). 在 (3) 中去掉收益约束，只留  $\mathbf{1}^T \mathbf{w} = 1$ ，解得

$$\mathbf{w}_{\text{gmv}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}} = \frac{\Sigma^{-1} \mathbf{1}}{C}, \quad \sigma_{\text{gmv}}^2 = \frac{1}{C}, \quad r_{\text{gmv}} = \frac{A}{C}. \quad (10)$$

证明. 由  $\Sigma \mathbf{w} = \gamma \mathbf{1}$  得  $\mathbf{w} = \gamma \Sigma^{-1} \mathbf{1}$ ；代入  $\mathbf{1}^T \mathbf{w} = 1$  得  $\gamma = 1/C$ 。方差  $\mathbf{w}^T \Sigma \mathbf{w} = \gamma^2 \mathbf{1}^T \Sigma^{-1} \mathbf{1} = C/C^2 = 1/C$ 。□

项目中以  $\sigma_{\text{gmv}}^2 = 1/C$  作为**数值自检**：闭式公式与  $\mathbf{w}_{\text{gmv}}^T \Sigma \mathbf{w}_{\text{gmv}}$  的误差为 0（机器精度）。

**命题 2** (切点/最大夏普组合). 设无风险收益为  $r_f$ 。在可投资无风险资产时，使夏普比  $S(\mathbf{w}) = (\boldsymbol{\mu}^T \mathbf{w} - r_f) / \sqrt{\mathbf{w}^T \Sigma \mathbf{w}}$  最大的组合为

$$\mathbf{w}_{\text{tan}} = \frac{\Sigma^{-1}(\boldsymbol{\mu} - r_f \mathbf{1})}{\mathbf{1}^T \Sigma^{-1}(\boldsymbol{\mu} - r_f \mathbf{1})}. \quad (11)$$

过点  $(0, r_f)$  与切点  $(\sigma_{\tan}, r_{\tan})$  的直线即 **资本市场线 (CML)**，其斜率等于最大夏普比，见图1。

**定理 1** (两基金分离定理). 由 (5)-(8)，前沿上任意组合  $\mathbf{w}(r) = \lambda(r) \Sigma^{-1} \boldsymbol{\mu} + \gamma(r) \Sigma^{-1} \mathbf{1}$  都是两支固定基金  $\Sigma^{-1} \boldsymbol{\mu}$  与  $\Sigma^{-1} \mathbf{1}$  的线性组合，且组合系数关于  $r$  仿射。因此只需两支前沿基金即可张成整条前沿。

## 4 矩阵算法要点

### 4.1 用 Cholesky 分解求解，而非显式求逆

上述闭式解需要  $\Sigma^{-1} \boldsymbol{\mu}$  与  $\Sigma^{-1} \mathbf{1}$ 。直接计算  $\Sigma^{-1}$  代价高且数值不稳。由于  $\Sigma \succ 0$ ，存在唯一下三角  $\mathbf{L}$  使

$$\Sigma = \mathbf{L} \mathbf{L}^T \quad (\text{Cholesky 分解}). \quad (12)$$

于是解  $\Sigma \mathbf{x} = \mathbf{b}$  化为两步三角求解：前代解  $\mathbf{L} \mathbf{y} = \mathbf{b}$ ，回代解  $\mathbf{L}^T \mathbf{x} = \mathbf{y}$ 。本项目在 `analytic.py` 中手写前代/回代以体现该矩阵算法。其复杂度  $O(n^3/3)$  优于通用求逆，且条件数更友好。

### 4.2 特征分解与条件数

对称正定阵可正交对角化  $\Sigma = \mathbf{Q} \boldsymbol{\Lambda} \mathbf{Q}^T$ ，特征值  $\lambda_1 \geq \dots \geq \lambda_n > 0$ 。**条件数**  $\kappa(\Sigma) = \lambda_1/\lambda_n$  衡量求解的数值稳定性；它也决定了第 5 节投影梯度下降的收敛速度。特征向量则可解释为**风险主成分**（最大特征值方向即市场系统性风险方向）。

### 4.3 正定性 $\Leftrightarrow$ 凸性 $\Rightarrow$ 全局最优

目标  $f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}^T \mathbf{w}$  的 Hessian 为  $\nabla^2 f = \Sigma$ 。 $\Sigma \succ 0$  即  $f$  **严格凸**，故任何满足 KKT 的平稳点都是唯一全局最优——这正是上一节闭式解全局最优的理论依据。

## 5 数值解：投影梯度下降

### 5.1 为什么需要数值法

加入不可卖空约束后，问题变为带不等式的二次规划

$$\min_{\mathbf{w}} \frac{1}{2} \mathbf{w}^T \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}^T \mathbf{w} \quad \text{s.t.} \quad \mathbf{1}^T \mathbf{w} = 1, \quad \mathbf{w} \geq \mathbf{0}. \quad (13)$$

可行域是**概率单纯形**  $\Delta = \{\mathbf{w} : \mathbf{w} \geq \mathbf{0}, \mathbf{1}^T \mathbf{w} = 1\}$ 。不等式约束使乘子需满足互补松弛，一般没有闭式解，须迭代求解。

## 5.2 投影梯度下降 (PGD)

PGD 交替执行“沿负梯度走一步”与“投影回可行域”：

$$\mathbf{w}_{k+1} = \text{Proj}_{\Delta}(\mathbf{w}_k - \eta \nabla f(\mathbf{w}_k)), \quad \nabla f(\mathbf{w}) = \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}. \quad (14)$$

## 5.3 单纯形欧氏投影的推导

投影本身是一个子优化问题：

$$\text{Proj}_{\Delta}(\mathbf{v}) = \arg \min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w} - \mathbf{v}\|^2 \quad \text{s.t.} \quad \mathbf{1}^T \mathbf{w} = 1, \mathbf{w} \geq \mathbf{0}. \quad (15)$$

写 KKT (乘子  $\tau \in \mathbb{R}$  对应等式,  $\beta \geq \mathbf{0}$  对应  $\mathbf{w} \geq \mathbf{0}$ ):

$$(w_i - v_i) + \tau - \beta_i = 0, \quad \beta_i \geq 0, \quad w_i \geq 0, \quad \beta_i w_i = 0.$$

由互补松弛：若  $w_i > 0$  则  $\beta_i = 0$ , 得  $w_i = v_i - \tau$ ; 若  $w_i = 0$  则需  $v_i \leq \tau$ 。合并：

$$\boxed{w_i = \max(v_i - \tau, 0)}, \quad \tau \text{ 由 } \sum_i \max(v_i - \tau, 0) = 1 \text{ 唯一确定}. \quad (16)$$

求阈值  $\tau$  的高效算法 (排序法)：将  $\mathbf{v}$  降序排成  $u_1 \geq \dots \geq u_n$ , 令

$$\rho = \max \left\{ j : u_j - \frac{1}{j} \left( \sum_{i \leq j} u_i - 1 \right) > 0 \right\}, \quad \tau = \frac{1}{\rho} \left( \sum_{i \leq \rho} u_i - 1 \right), \quad (17)$$

复杂度  $O(n \log n)$ 。该算法在 `numeric.py` 的 `project_to_simplex` 中实现。

## 5.4 收敛性分析

$f$  的梯度  $\nabla f(\mathbf{w}) = \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}$  关于  $\mathbf{w}$  是利普希茨连续的, 常数  $L = \lambda_{\max}(\Sigma)$ ; 同时  $f$  以  $m = \lambda_{\min}(\Sigma) > 0$  强凸。取步长  $\eta = 1/L$ , 标准结果给出：

- 仅用凸性:  $f(\mathbf{w}_k) - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|^2}{2k} = O(1/k)$ ;
- 利用强凸 (本问题  $\Sigma \succ 0$ ): **线性 (几何) 收敛**  $\|\mathbf{w}_k - \mathbf{w}^*\|^2 \leq \left(1 - \frac{m}{L}\right)^k \|\mathbf{w}_0 - \mathbf{w}^*\|^2$ , 速率由条件数  $\kappa = L/m$  决定。

图3 (左) 中  $f(\mathbf{w}_k) - f^*$  在对数轴上近似直线下降, 正是**线性收敛**的体现, 与强凸理论一致。

# 6 机器学习联系：协方差矩阵的收缩估计

实践中  $\boldsymbol{\mu}, \Sigma$  未知, 须从历史收益估计。样本协方差  $\mathbf{S}$  虽无偏, 但在 **维数高 / 样本少** 时方差大、接近奇异 (条件数巨大), 导致  $\Sigma^{-1}$  放大噪声、优化权重极端不稳。**Ledoit-Wolf 收缩估计** 是一种统计学习 (正则化) 方法, 把  $\mathbf{S}$  向结构化目标  $\mathbf{F} = m\mathbf{I}$  ( $m = \text{tr}(\mathbf{S})/n$  为平均方差) 收缩：

$$\Sigma_{\text{LW}} = \delta (m\mathbf{I}) + (1 - \delta) \mathbf{S}, \quad \delta \in [0, 1]. \quad (18)$$

最优收缩强度  $\delta^*$  由最小化期望误差  $\mathbb{E}\|\Sigma_{LW} - \Sigma_{\text{true}}\|^2$  解析给出 (见 `data_utils.py`)，本质是**偏差-方差权衡**： $S$  无偏但高方差， $mI$  有偏但低方差， $\delta^*$  自动折中。图4 (右) 定量显示：样本越少， $S$  的条件数越爆炸，而  $\Sigma_{LW}$  始终良态——这正是“机器学习改善估计”在本问题中的体现。

## 7 实验与结果

数据为合成的 8 只股票 (科技/金融/消费三行业)、约 3 年日收益率，用三因子模型生成，保留真实的行业块状相关结构 (图4 左)。全流程口径年化，无风险利率取  $r_f = 3\%$ 。




图 1: 均值-方差有效前沿 (解析, 允许卖空)。红星为 GMV, 绿菱为切点组合, 虚线为资本市场线 (斜率=最大夏普比)。




图 2: 可行域、单资产与前沿。散点为随机长仓组合（按夏普比着色），三角为单只股票。单资产均位于前沿内侧，说明**分散化**可在同等收益下显著降低风险。




图 3: 左: 投影梯度下降的目标值误差  $f(w_k) - f^*$  (对数轴, 呈线性收敛)。右: 长仓 ( $w \geq 0$ ) 数值前沿位于允许卖空的解析前沿内侧, 高收益端差距明显, 说明不可卖空约束牺牲了一部分可达收益。




图 4: 左: 相关系数矩阵, 行业内相关明显高于行业间 (块状结构)。右: 条件数随估计窗口长度  $T$  的变化——样本越少, 样本协方差越病态, 而 Ledoit-Wolf 收缩始终保持良态。




图 5: 三种代表性组合的资产权重。切点组合 (允许卖空) 出现明显负权重 (做空低收益资产), 而长仓最小方差组合全部非负——直观展示约束  $w \geq 0$  的影响。

**结果解读。** GMV 把资金集中到低波动的金融/消费股, 年化波动最低; 切点组合通过做空低收益资产、做多高夏普资产取得最高夏普比; 加入不可卖空约束后, 前沿整体内移、可达收益上限下降。所有解析结论均通过数值自检 ( $\sigma_{\text{gmV}}^2 = 1/C$ 、权重和为 1、KKT 残差  $\approx 0$ 、自研 PGD 与 scipy 的 SLSQP 解最大偏差  $< 10^{-3}$ ), 见 `results/summary.json`。

## 8 随机矩阵理论与自助法推断（样本外实验补充）

### 8.1 Marchenko–Pastur 定理与特征值裁剪

设  $T \times n$  数据矩阵的行向量为 i.i.d. 纯噪声（方差  $\sigma^2$ ）。当  $T, n \rightarrow \infty$ 、 $q = n/T$  固定时，样本相关矩阵的特征值依分布收敛到 Marchenko–Pastur 律

$$\rho(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi q \sigma^2 \lambda}, \quad \lambda_{\pm} = \sigma^2(1 \pm \sqrt{q})^2, \quad (19)$$

支撑为  $[\lambda_-, \lambda_+]$ 。于是凡落入噪声带的样本特征值与纯噪声在统计上不可区分，只有  $\lambda > \lambda_+$  的特征值才携带真实相关结构（市场/行业因子）。

**裁剪估计量（Bouchaud–Potters 配方）。** 对样本相关阵作特征分解  $C = V\Lambda V^T$ ，把  $\lambda_i \leq \lambda_+$  的噪声特征值替换为它们的均值（**保迹**： $\sum_i \lambda'_i = \text{tr } C = n$ ），重构  $C' = V\Lambda'V^T$  后重新归一使对角恰为 1，再乘回样本标准差得  $\Sigma_{\text{RMT}}$ 。

**因子估计量。** 只保留  $k = \#\{\lambda_i > \lambda_+\}$  个信号特征对：

$$C_f = \sum_{i \leq k} \lambda_i v_i v_i^T + D, \quad D_{jj} = 1 - \sum_{i \leq k} \lambda_i v_{ij}^2 = \sum_{i > k} \lambda_i v_{ij}^2 \geq 0, \quad (20)$$

对角残差使  $C_f$  半正定且对角为 1。由迹约束知平均特征值为  $1 < \lambda_+$ ，故必有  $k < n$ （全部特征值超界将使迹超过  $n\lambda_+ > n$ ，矛盾）。

**低维警示。** 本项目  $q = 8/252 \approx 0.032$ ， $\lambda_+ \approx 1.39$ ，噪声带很窄。实验中全部 108 个滚动窗口都只有市场因子（ $\lambda \approx 3 \sim 4$ ）超出  $\lambda_+$ ，三个行业因子在统计上与噪声不可分而被一并裁掉——裁剪后的  $\Sigma$  低估行业内相关，反而令切点组合的杠杆更极端（样本外夏普  $-0.56$ ，劣于直接用样本协方差）。RMT 是  $n/T$  较大时的高维武器；低维时样本协方差本不病态，谱手术的收益预期有限，甚至为负。

### 8.2 Circular block bootstrap 与夏普差检验

单条样本外收益路径给出的夏普比率只是点估计。设  $m$  个策略的样本外日收益矩阵为  $R \in \mathbb{R}^{T \times m}$ ，第  $b$  次重采样以块长  $\ell$ （取再平衡周期 21 天）生成环形块索引：块起点独立同分布于  $U\{0, \dots, T-1\}$ ，每块取连续  $\ell$  天（模  $T$  回绕），拼接后截断到长度  $T$ ——块内的波动聚集等时序依赖得以保留。

关键设计是**联合重采**：同一组索引同时作用于  $R$  的全部  $m$  列，保留策略间的截面相关。如此夏普差  $\Delta_b = \widehat{\text{SR}}_b^{(i)} - \widehat{\text{SR}}_b^{(j)}$  中共同的市场波动相互抵消，检验才有功效；若各列独立重采， $\Delta$  的方差将被严重高估。每个 resample 内**整段重算**年化夏普（均值与波动在同一 resample 内相关，不可分别抽样再组合）。双侧  $p$  值采用  $(\# + 1)/(B + 1)$  修正以避免报出  $p = 0$ 。

**实验结论。**  $B = 2000$  次重采样下，全部策略相对等权  $1/N$  的  $\Delta\text{Sharpe}$  置信区间均横跨 0（最小  $p = 0.079$ ）：在一条 9 年的样本外路径上，连使用真实  $\mu$  的 Oracle 切点组合都无法在统计上显著胜过  $1/N$ （ $p = 0.85$ ）。这把 DeMiguel et al. (2009) 的结论又推进一步——不仅估计误差会摧毁样本内最优，而且单条路径的噪声之大，使任何“跑赢”都难以被证实。

## 9 给期望收益开药方、维数相变与最优协方差

### 9.1 Jorion 的 Bayes–Stein 收缩

既然实验证明  $\mu$  的估计误差是样本外失败的元凶，经典药方是对  $\mu$  本身做收缩（与 Ledoit–Wolf 对  $\Sigma$  的收缩完全对仗）。Jorion (1986) 把样本均值  $\hat{\mu}$  向 GMV 隐含收益  $\mu_0 = \frac{\mathbf{1}^\top \Sigma^{-1} \hat{\mu}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}$  收缩：

$$\mu_{\text{BS}} = (1 - \hat{w}) \hat{\mu} + \hat{w} \mu_0 \mathbf{1}, \quad \hat{w} = \frac{n + 2}{(n + 2) + T (\hat{\mu} - \mu_0 \mathbf{1})^\top \Sigma^{-1} (\hat{\mu} - \mu_0 \mathbf{1})} \in (0, 1]. \quad (21)$$

收缩强度由  $\hat{\mu}$  偏离目标的马氏距离决定：偏离越像噪声（相对于  $T$  个样本的抽样误差），收缩越狠。实验中  $\hat{w} \in [0.39, 0.81]$ ， $\mu$  的平均估计误差从 0.77 降到 0.49（年化  $\ell_2$  范数），切点组合换手率近乎减半。

### 9.2 Black–Litterman 均衡先验与”无观点定理”

从”市场组合即等权  $w_{\text{eq}} = \mathbf{1}/n$ ”反向优化出均衡隐含收益

$$\pi = r_f \mathbf{1} + \delta \Sigma w_{\text{eq}}, \quad \delta = \frac{\bar{r}_{\text{mkt}} - r_f}{\sigma_{\text{mkt}}^2}. \quad (22)$$

以  $\pi$  为输入的切点组合权重为  $w \propto \Sigma^{-1}(\pi - r_f \mathbf{1}) = \delta w_{\text{eq}}$ ，归一化后恰好还原  $w_{\text{eq}}$ （ $\delta$  在归一化中消去）——不持有观点的贝叶斯投资者就该持有市场。实验对全部 108 个滚动窗口数值验证： $\max |w_{\text{BL}} - \mathbf{1}/n| \approx 10^{-15}$ （机器精度）。

进一步做收缩路径扫描  $\mu_\varphi = (1 - \varphi)\pi + \varphi \hat{\mu}$ ：最优在  $\varphi^* = 0$ （纯均衡），且中间  $\varphi$  并非平滑过渡而是剧烈震荡——当混合后的超额收益向量  $\mu_\varphi - r_f \mathbf{1}$  接近零向量时，切点归一化因子  $\mathbf{1}^\top \Sigma^{-1}(\mu_\varphi - r_f \mathbf{1})$  趋零，权重爆炸。在这条样本路径上，样本信息掺入多少都只会伤害组合。

### 9.3 维数相变：RMT 的翻案

固定  $T = 252$ 、把资产数从  $n = 8$  扫到 200（ $q = n/T$  从 0.03 到 0.79），数据生成过程同构、真实信号秩恒为 4。以 GMV 的样本外实现波动衡量  $\hat{\Sigma}$  的质量（不经过  $\mu$ ）： $q$  小时四种估计并列； $q \rightarrow 1$  时样本协方差条件数爆炸（中位数  $\approx 1.1 \times 10^4$ ），其 GMV 波动回升到与等权持平——维数带来的分散化红利被估计误差悉数吃掉；而 MP 裁剪与

PCA 因子估计只保留  $O(1)$  个信号特征对，对维数免疫，波动持续下降（18%  $\rightarrow$  9%）。RMT 在  $q$  小时是误伤真实因子的手术刀，在  $q$  大时是唯一的救命稻草——任何估计量都有其适用边界。

## 9.4 最优协方差：解析非线性收缩

线性收缩 (LW2004) 把特征值朝同一常数拉、RMT 裁剪把噪声压成台阶，都是“一刀切”。Ledoit–Wolf (2020) 的**非线性收缩**保持特征向量不变，只对每个样本特征值  $\lambda_i$  施加一个最优的、连续变化的缩放

$$\tilde{d}_i = \frac{\lambda_i}{(\pi c \lambda_i \tilde{f}(\lambda_i))^2 + (1 - c - \pi c \lambda_i \mathcal{H}\tilde{f}(\lambda_i))^2}, \quad c = \frac{p}{n}, \quad (23)$$

其中样本谱密度  $\tilde{f}$  及其 Hilbert 变换  $\mathcal{H}\tilde{f}$  由带宽  $h = n^{-1/3}$  的 Epanechnikov 核估计。该式是 Frobenius 范数下最优旋转等变估计的渐近实现：小特征值（被噪声压低）被抬高、大特征值（被高估）被压低。实验用纯 numpy 从零实现（特征分解 + 核密度 + Hilbert 变换解析式 + 上式），并数值验证其与样本协方差对易（仅改特征值，相对残差  $\sim 10^{-15}$ ）。效果上 NLS”从不更差”： $n = 8$  时贴近样本协方差， $n = 200$  时将条件数中位数从 10994 压到 217、GMV 实现波动从 17.5% 降到 9.4%，紧贴因子模型的最优表现，却无需假设因子数、也不在低维误伤真实信号——为协方差估计给出理论与实践统一的最优解。

# 10 结论

本项目以矩阵算法为主线，完整走通了一个量化金融多目标规划问题：从双目标建模、标量化，到拉格朗日/KKT 闭式解（依托 Cholesky 与特征分解）、再到不可卖空约束下从零实现的投影梯度下降（含单纯形投影推导与收敛性分析），最后用 Ledoit–Wolf 收缩把机器学习的正则化思想引入协方差估计。在此基础上，样本外滚动回测量化了  $\mu$  估计误差的真实代价，随机矩阵理论与 block bootstrap 揭示了协方差谱手术的低维局限与回测结论本身的统计不确定性，Bayes–Stein 收缩与 Black–Litterman 均衡先验给出了  $\mu$  的可行药方，维数扫描画出了每种估计量的适用边界，解析非线性收缩则为协方差估计给出理论最优解。理论推导、代码实现、图像与数值自检相互印证，可作为矩阵算法课程的完整范例。