

均值-方差投资组合的多目标规划： 矩阵算法、解析解与投影梯度下降

矩阵算法课程项目

2026 年 6 月 10 日

摘要

本项目把量化金融中最经典的资产配置问题——Markowitz 均值-方差模型——建模为一个 **双目标规划问题**（同时最大化期望收益、最小化风险），并从**矩阵算法**的视角给出完整推导与实现。我们：(1) 用拉格朗日乘子法与 KKT 条件导出允许卖空时有效前沿的 **闭式解**，核心是对对称正定协方差矩阵 Σ 的求逆/求解（Cholesky 分解）；(2) 在加入不可卖空约束 $w \geq 0$ 后问题失去闭式解，于是**从零实现投影梯度下降**（含单纯形欧氏投影的 KKT 推导与收敛性分析）；(3) 用 Ledoit-Wolf 收缩估计这一 **统计学习（机器学习）** 方法改善 Σ 的估计，并定量展示其在小样本/高维时的价值。全部结论在合成但统计特征真实的 8 资产数据上验证，并附 5 张图像。

目录

1	问题背景与现实意义	1
2	多目标规划建模	2
2.1	符号与假设	2
2.2	双目标模型	2
2.3	标量化：把多目标化为单目标	2
3	解析解：拉格朗日乘子与 KKT 条件	2
3.1	一阶最优性条件	2
3.2	消去乘子：一个 2×2 线性系统	3
3.3	有效前沿的闭式表达	3
3.4	两个关键组合	3
4	矩阵算法要点	4
4.1	用 Cholesky 分解求解，而非显式求逆	4
4.2	特征分解与条件数	4

1 问题背景与现实意义	2
4.3 正定性 $\Leftrightarrow$ 凸性 $\Rightarrow$ 全局最优	4
5 数值解：投影梯度下降	4
5.1 为什么需要数值法	4
5.2 投影梯度下降 (PGD)	5
5.3 单纯形欧氏投影的推导	5
5.4 收敛性分析	5
6 机器学习联系：协方差矩阵的收缩估计	5
7 实验与结果	6
8 随机矩阵理论与自助法推断 (样本外实验补充)	9
8.1 Marchenko–Pastur 定理与特征值裁剪	9
8.2 Circular block bootstrap 与夏普差检验	9
9 给期望收益开药方：Bayes–Stein 收缩、Black–Litterman 与维数相变	10
9.1 Jorion 的 Bayes–Stein 收缩	10
9.2 Black–Litterman 均衡先验与”无观点定理”	10
9.3 维数相变：RMT 的翻案	10
10 结论	11

1 问题背景与现实意义

设某投资者面对 n 只股票，需决定把资金按比例 $\mathbf{w} = (w_1, \dots, w_n)^\top$ 配置到各资产上 (w_i 为第 i 只股票的权重, $\sum_i w_i = 1$)。投资者的两个目标天然冲突：

- **收益越高越好**：组合期望收益为 $\boldsymbol{\mu}^\top \mathbf{w}$ ，其中 $\boldsymbol{\mu} \in \mathbb{R}^n$ 是各资产期望收益；
- **风险越低越好**：组合方差为 $\mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w}$ ，其中 $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$ 是收益的协方差矩阵。

高收益资产往往伴随高波动，因此不存在同时让两者最优的单一解，而是一族**折中 (Pareto) 解**。寻找这族解、并理解“多承担一单位风险能换来多少额外收益”，正是资产配置的核心，也是一个标准的**多目标规划**问题。其数学骨架完全由矩阵运算构成（二次型、矩阵求逆、特征分解），因此非常适合作为矩阵算法课程的综合案例。

2 多目标规划建模

2.1 符号与假设

记全 1 向量为 $\mathbf{1} \in \mathbb{R}^n$ 。假设 $\boldsymbol{\Sigma}$ **对称正定** ($\boldsymbol{\Sigma} \succ 0$) ——这在样本协方差中当观测期数 $T > n$ 且无完全共线资产时几乎必然成立，也保证了二次型 $\mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w} > 0$ （任意非零组

合都有正风险) 以及目标函数的**严格凸性**。

2.2 双目标模型

$$\min_w \left(\mathbf{w}^\top \Sigma \mathbf{w}, -\boldsymbol{\mu}^\top \mathbf{w} \right) \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1, \quad (\text{可选}) \quad \mathbf{w} \geq \mathbf{0}. \quad (1)$$

约束 $\mathbf{1}^\top \mathbf{w} = 1$ 表示资金全部投出; $\mathbf{w} \geq \mathbf{0}$ 表示**不可卖空** (只能买入)。

定义 1 (Pareto 最优). 可行解 $\mathbf{w}^*$ 称为 Pareto 最优, 若不存在另一可行解 $\mathbf{w}$ 使得两个目标都不更差、且至少一个严格更优。所有 Pareto 最优组合在 $(\sigma, r) = (\sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}, \boldsymbol{\mu}^\top \mathbf{w})$ 平面上的像称为**有效前沿** (efficient frontier)。

2.3 标量化：把多目标化为单目标

求解多目标规划的常用手段是**标量化**, 即用一个标量参数把两目标合成一个目标, 扫描该参数即可得到整条前沿。本文用两种等价方式:

(a) **加权和法**。引入风险偏好系数 $\lambda \geq 0$:

$$\min_w \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}^\top \mathbf{w} \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1. \quad (2)$$

$\lambda = 0$ 对应纯最小方差; $\lambda \rightarrow \infty$ 对应纯最大收益。

(b) **ε -约束法**。固定一个目标收益 r , 最小化风险:

$$\min_w \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} \quad \text{s.t.} \quad \boldsymbol{\mu}^\top \mathbf{w} = r, \quad \mathbf{1}^\top \mathbf{w} = 1. \quad (3)$$

扫描 r 即得前沿。由于 $\Sigma \succ 0$ 使目标严格凸、约束为线性, 两种标量化都给出**唯一全局最优**, 且其解集相同 (KKT 充要)。下一节用 (3) 推导闭式解。

3 解析解：拉格朗日乘子与 KKT 条件

3.1 一阶最优性条件

对 (3) 写拉格朗日函数 (λ, γ 为乘子):

$$\mathcal{L}(\mathbf{w}, \lambda, \gamma) = \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} - \lambda(\boldsymbol{\mu}^\top \mathbf{w} - r) - \gamma(\mathbf{1}^\top \mathbf{w} - 1). \quad (4)$$

对 $\mathbf{w}$ 求梯度并令其为零 (这就是等式约束下的 KKT 平稳性条件):

$$\nabla_w \mathcal{L} = \Sigma \mathbf{w} - \lambda \boldsymbol{\mu} - \gamma \mathbf{1} = \mathbf{0} \implies \boxed{\mathbf{w} = \Sigma^{-1}(\lambda \boldsymbol{\mu} + \gamma \mathbf{1})}. \quad (5)$$

因目标严格凸、约束线性, 该平稳点即**全局最优**。

3.2 消去乘子：一个 2×2 线性系统

把 (5) 代入两个约束，并定义四个由矩阵 Σ 决定的标量

$$A = \mathbf{1}^\top \Sigma^{-1} \boldsymbol{\mu}, \quad B = \boldsymbol{\mu}^\top \Sigma^{-1} \boldsymbol{\mu}, \quad C = \mathbf{1}^\top \Sigma^{-1} \mathbf{1}, \quad D = BC - A^2, \quad (6)$$

得到

$$\begin{cases} \boldsymbol{\mu}^\top \mathbf{w} = \lambda B + \gamma A = r, \\ \mathbf{1}^\top \mathbf{w} = \lambda A + \gamma C = 1, \end{cases} \iff \begin{bmatrix} B & A \\ A & C \end{bmatrix} \begin{bmatrix} \lambda \\ \gamma \end{bmatrix} = \begin{bmatrix} r \\ 1 \end{bmatrix}. \quad (7)$$

该系数矩阵的行列式恰为 $D = BC - A^2$ 。由 Cauchy-Schwarz 不等式（在内积 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \Sigma^{-1} \mathbf{y}$ 下）可证 $D > 0$ （当 $\boldsymbol{\mu}$ 与 $\mathbf{1}$ 线性无关），故系统可解：

$$\lambda = \frac{Cr - A}{D}, \quad \gamma = \frac{B - Ar}{D}. \quad (8)$$

3.3 有效前沿的闭式表达

最优组合的方差可由 (5) 巧妙化简（利用 $\mathbf{w}^\top \Sigma \mathbf{w} = \mathbf{w}^\top (\lambda \boldsymbol{\mu} + \gamma \mathbf{1}) = \lambda r + \gamma$ ）：

$$\sigma^2(r) = \mathbf{w}^\top \Sigma \mathbf{w} = \frac{Cr^2 - 2Ar + B}{D}. \quad (9)$$

这是 (σ^2, r) 平面上的**抛物线**、 (σ, r) 平面上的**双曲线**——即图1 中的有效前沿。其顶点（最小方差点）由 $d\sigma^2/dr = 0$ 给出。

3.4 两个关键组合

命题 1 (全局最小方差组合 GMV). 在 (3) 中去掉收益约束，只留 $\mathbf{1}^\top \mathbf{w} = 1$ ，解得

$$\mathbf{w}_{\text{gmV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} = \frac{\Sigma^{-1} \mathbf{1}}{C}, \quad \sigma_{\text{gmV}}^2 = \frac{1}{C}, \quad r_{\text{gmV}} = \frac{A}{C}. \quad (10)$$

证明. 由 $\Sigma \mathbf{w} = \gamma \mathbf{1}$ 得 $\mathbf{w} = \gamma \Sigma^{-1} \mathbf{1}$ ；代入 $\mathbf{1}^\top \mathbf{w} = 1$ 得 $\gamma = 1/C$ 。方差 $\mathbf{w}^\top \Sigma \mathbf{w} = \gamma^2 \mathbf{1}^\top \Sigma^{-1} \mathbf{1} = C/C^2 = 1/C$ 。□

项目中以 $\sigma_{\text{gmV}}^2 = 1/C$ 作为**数值自检**：闭式公式与 $\mathbf{w}_{\text{gmV}}^\top \Sigma \mathbf{w}_{\text{gmV}}$ 的误差为 0（机器精度）。

命题 2 (切点/最大夏普组合). 设无风险收益为 r_f 。在可投资无风险资产时，使夏普比 $S(\mathbf{w}) = (\boldsymbol{\mu}^\top \mathbf{w} - r_f) / \sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}$ 最大的组合为

$$\mathbf{w}_{\text{tan}} = \frac{\Sigma^{-1}(\boldsymbol{\mu} - r_f \mathbf{1})}{\mathbf{1}^\top \Sigma^{-1}(\boldsymbol{\mu} - r_f \mathbf{1})}. \quad (11)$$

过点 $(0, r_f)$ 与切点 $(\sigma_{\text{tan}}, r_{\text{tan}})$ 的直线即 **资本市场线 (CML)**，其斜率等于最大夏普比，见图1。

定理 1 (两基金分离定理). 由 (5)–(8)，前沿上任意组合 $\mathbf{w}(r) = \lambda(r) \Sigma^{-1} \boldsymbol{\mu} + \gamma(r) \Sigma^{-1} \mathbf{1}$ 都是两支固定基金 $\Sigma^{-1} \boldsymbol{\mu}$ 与 $\Sigma^{-1} \mathbf{1}$ 的线性组合，且组合系数关于 r 仿射。因此只需两支前沿基金即可张成整条前沿。

4 矩阵算法要点

4.1 用 Cholesky 分解求解，而非显式求逆

上述闭式解需要 $\Sigma^{-1}\mu$ 与 $\Sigma^{-1}\mathbf{1}$ 。直接计算 Σ^{-1} 代价高且数值不稳。由于 $\Sigma \succ 0$ ，存在唯一下三角 L 使

$$\Sigma = LL^T \quad (\text{Cholesky 分解}). \quad (12)$$

于是解 $\Sigma x = b$ 化为两步三角求解：前代解 $Ly = b$ ，回代解 $L^T x = y$ 。本项目在 `analytic.py` 中手写前代/回代以体现该矩阵算法。其复杂度 $O(n^3/3)$ 优于通用求逆，且条件数更友好。

4.2 特征分解与条件数

对称正定阵可正交对角化 $\Sigma = Q\Lambda Q^T$ ，特征值 $\lambda_1 \geq \dots \geq \lambda_n > 0$ 。**条件数** $\kappa(\Sigma) = \lambda_1/\lambda_n$ 衡量求解的数值稳定性；它也决定了第 5 节投影梯度下降的收敛速度。特征向量则可解释为**风险主成分**（最大特征值方向即市场系统性风险方向）。

4.3 正定性 $\Leftrightarrow$ 凸性 $\Rightarrow$ 全局最优

目标 $f(w) = \frac{1}{2}w^T \Sigma w - \lambda \mu^T w$ 的 Hessian 为 $\nabla^2 f = \Sigma$ 。 $\Sigma \succ 0$ 即 f **严格凸**，故任何满足 KKT 的平稳点都是唯一全局最优——这正是上一节闭式解全局最优的理论依据。

5 数值解：投影梯度下降

5.1 为什么需要数值法

加入不可卖空约束后，问题变为带不等式的二次规划

$$\min_w \frac{1}{2} w^T \Sigma w - \lambda \mu^T w \quad \text{s.t.} \quad \mathbf{1}^T w = 1, \quad w \geq 0. \quad (13)$$

可行域是**概率单纯形** $\Delta = \{w : w \geq 0, \mathbf{1}^T w = 1\}$ 。不等式约束使乘子需满足互补松弛，一般没有闭式解，须迭代求解。

5.2 投影梯度下降 (PGD)

PGD 交替执行“沿负梯度走一步”与“投影回可行域”：

$$w_{k+1} = \text{Proj}_\Delta(w_k - \eta \nabla f(w_k)), \quad \nabla f(w) = \Sigma w - \lambda \mu. \quad (14)$$

5.3 单纯形欧氏投影的推导

投影本身是一个子优化问题：

$$\text{Proj}_\Delta(\mathbf{v}) = \arg \min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w} - \mathbf{v}\|^2 \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1, \mathbf{w} \geq \mathbf{0}. \quad (15)$$

写 KKT (乘子 $\tau \in \mathbb{R}$ 对应等式, $\beta \geq \mathbf{0}$ 对应 $\mathbf{w} \geq \mathbf{0}$):

$$(w_i - v_i) + \tau - \beta_i = 0, \quad \beta_i \geq 0, \quad w_i \geq 0, \quad \beta_i w_i = 0.$$

由互补松弛：若 $w_i > 0$ 则 $\beta_i = 0$, 得 $w_i = v_i - \tau$; 若 $w_i = 0$ 则需 $v_i \leq \tau$ 。合并：

$$\boxed{w_i = \max(v_i - \tau, 0)}, \quad \tau \text{ 由 } \sum_i \max(v_i - \tau, 0) = 1 \text{ 唯一确定}. \quad (16)$$

求阈值 τ 的高效算法 (排序法)：将 $\mathbf{v}$ 降序排成 $u_1 \geq \dots \geq u_n$, 令

$$\rho = \max \left\{ j : u_j - \frac{1}{j} \left(\sum_{i \leq j} u_i - 1 \right) > 0 \right\}, \quad \tau = \frac{1}{\rho} \left(\sum_{i \leq \rho} u_i - 1 \right), \quad (17)$$

复杂度 $O(n \log n)$ 。该算法在 `numeric.py` 的 `project_to_simplex` 中实现。

5.4 收敛性分析

f 的梯度 $\nabla f(\mathbf{w}) = \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}$ 关于 $\mathbf{w}$ 是**利普希茨连续**的, 常数 $L = \lambda_{\max}(\Sigma)$; 同时 f 以 $m = \lambda_{\min}(\Sigma) > 0$ **强凸**。取步长 $\eta = 1/L$, 标准结果给出：

- 仅用凸性： $f(\mathbf{w}_k) - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|^2}{2k} = O(1/k)$;
- 利用强凸 (本问题 $\Sigma \succ 0$)：**线性 (几何) 收敛** $\|\mathbf{w}_k - \mathbf{w}^*\|^2 \leq \left(1 - \frac{m}{L}\right)^k \|\mathbf{w}_0 - \mathbf{w}^*\|^2$, 速率由条件数 $\kappa = L/m$ 决定。

图3 (左) 中 $f(\mathbf{w}_k) - f^*$ 在对数轴上近似直线下降, 正是**线性收敛**的体现, 与强凸理论一致。

6 机器学习联系：协方差矩阵的收缩估计

实践中 $\boldsymbol{\mu}, \Sigma$ 未知, 须从历史收益估计。样本协方差 $\mathbf{S}$ 虽无偏, 但在 **维数高 / 样本少** 时方差大、接近奇异 (条件数巨大), 导致 Σ^{-1} 放大噪声、优化权重极端不稳。**Ledoit-Wolf 收缩估计** 是一种统计学习 (正则化) 方法, 把 $\mathbf{S}$ 向结构化目标 $\mathbf{F} = m\mathbf{I}$ ($m = \text{tr}(\mathbf{S})/n$ 为平均方差) 收缩：

$$\Sigma_{\text{LW}} = \delta (m\mathbf{I}) + (1 - \delta) \mathbf{S}, \quad \delta \in [0, 1]. \quad (18)$$

最优收缩强度 δ^* 由最小化期望误差 $\mathbb{E} \|\Sigma_{\text{LW}} - \Sigma_{\text{true}}\|^2$ 解析给出 (见 `data_utils.py`), 本质是**偏差-方差权衡**： $\mathbf{S}$ 无偏但高方差, $m\mathbf{I}$ 有偏但低方差, δ^* 自动折中。图4 (右) 定量显示：样本越少, $\mathbf{S}$ 的条件数越爆炸, 而 Σ_{LW} 始终良态——这正是“机器学习改善估计”在本问题中的体现。

7 实验与结果

数据为合成的 8 只股票（科技/金融/消费三行业）、约 3 年日收益率，用三因子模型生成，保留真实的行业块状相关结构（图4 左）。全流程口径年化，无风险利率取 $r_f = 3\%$ 。




图 1: 均值-方差有效前沿（解析，允许卖空）。红星为 GMV，绿菱为切点组合，虚线为资本市场线（斜率=最大夏普比）。




图 2: 可行域、单资产与前沿。散点为随机长仓组合（按夏普比着色），三角为单只股票。单资产均位于前沿内侧，说明**分散化**可在同等收益下显著降低风险。




图 3: 左: 投影梯度下降的目标值误差 $f(\mathbf{w}_k) - f^*$ (对数轴, 呈线性收敛)。右: 长仓 ($\mathbf{w} \geq 0$) 数值前沿位于允许卖空的解析前沿内侧, 高收益端差距明显, 说明不可卖空约束牺牲了一部分可达收益。




图 4: 左: 相关系数矩阵, 行业内相关明显高于行业间 (块状结构)。右: 条件数随估计窗口长度 T 的变化——样本越少, 样本协方差越病态, 而 Ledoit-Wolf 收缩始终保持良态。




图 5: 三种代表性组合的资产权重。切点组合 (允许卖空) 出现明显负权重 (做空低收益资产), 而长仓最小方差组合全部非负——直观展示约束 $w \geq 0$ 的影响。

结果解读。 GMV 把资金集中到低波动的金融/消费股, 年化波动最低; 切点组合通过做空低收益资产、做多高夏普资产取得最高夏普比; 加入不可卖空约束后, 前沿整体内移、可达收益上限下降。所有解析结论均通过数值自检 ($\sigma_{\text{gmV}}^2 = 1/C$ 、权重和为 1、KKT 残差 ≈ 0 、自研 PGD 与 `scipy` 的 SLSQP 解最大偏差 $< 10^{-3}$), 见 `results/summary.json`。

8 随机矩阵理论与自助法推断（样本外实验补充）

8.1 Marchenko–Pastur 定理与特征值裁剪

设 $T \times n$ 数据矩阵的行向量为 i.i.d. 纯噪声（方差 σ^2 ）。当 $T, n \rightarrow \infty$ 、 $q = n/T$ 固定时，样本相关矩阵的特征值依分布收敛到 Marchenko–Pastur 律

$$\rho(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi q \sigma^2 \lambda}, \quad \lambda_{\pm} = \sigma^2(1 \pm \sqrt{q})^2, \quad (19)$$

支撑为 $[\lambda_-, \lambda_+]$ 。于是凡落入噪声带的样本特征值与纯噪声在统计上不可区分，只有 $\lambda > \lambda_+$ 的特征值才携带真实相关结构（市场/行业因子）。

裁剪估计量（Bouchaud–Potters 配方）。 对样本相关阵作特征分解 $C = V\Lambda V^T$ ，把 $\lambda_i \leq \lambda_+$ 的噪声特征值替换为它们的均值（**保迹**： $\sum_i \lambda'_i = \text{tr } C = n$ ），重构 $C' = V\Lambda'V^T$ 后重新归一使对角恰为 1，再乘回样本标准差得 Σ_{RMT} 。

因子估计量。 只保留 $k = \#\{\lambda_i > \lambda_+\}$ 个信号特征对：

$$C_f = \sum_{i \leq k} \lambda_i v_i v_i^T + D, \quad D_{jj} = 1 - \sum_{i \leq k} \lambda_i v_{ij}^2 = \sum_{i > k} \lambda_i v_{ij}^2 \geq 0, \quad (20)$$

对角残差使 C_f 半正定且对角为 1。由迹约束知平均特征值为 $1 < \lambda_+$ ，故必有 $k < n$ （全部特征值超界将使迹超过 $n\lambda_+ > n$ ，矛盾）。

低维警示。 本项目 $q = 8/252 \approx 0.032$ ， $\lambda_+ \approx 1.39$ ，噪声带很窄。实验中全部 108 个滚动窗口都只有市场因子（ $\lambda \approx 3 \sim 4$ ）超出 λ_+ ，三个行业因子在统计上与噪声不可分而被一并裁掉——裁剪后的 Σ 低估行业内相关，反而令切点组合的杠杆更极端（样本外夏普 -0.56 ，劣于直接用样本协方差）。RMT 是 n/T 较大时的高维武器；低维时样本协方差本不病态，谱手术的收益预期有限，甚至为负。

8.2 Circular block bootstrap 与夏普差检验

单条样本外收益路径给出的夏普比率只是点估计。设 m 个策略的样本外日收益矩阵为 $R \in \mathbb{R}^{T \times m}$ ，第 b 次重采样以块长 ℓ （取再平衡周期 21 天）生成环形块索引：块起点独立同分布于 $U\{0, \dots, T-1\}$ ，每块取连续 ℓ 天（模 T 回绕），拼接后截断到长度 T ——块内的波动聚集等时序依赖得以保留。

关键设计是**联合重采**：同一组索引同时作用于 R 的全部 m 列，保留策略间的截面相关。如此夏普差 $\Delta_b = \widehat{\text{SR}}_b^{(i)} - \widehat{\text{SR}}_b^{(j)}$ 中共同的市场波动相互抵消，检验才有功效；若各列独立重采， Δ 的方差将被严重高估。每个 resample 内**整段重算**年化夏普（均值与波动在同一 resample 内相关，不可分别抽样再组合）。双侧 p 值采用 $(\# + 1)/(B + 1)$ 修正以避免报出 $p = 0$ 。

实验结论。 $B = 2000$ 次重采样下，全部策略相对等权 $1/N$ 的 ΔSharpe 置信区间均横跨 0（最小 $p = 0.079$ ）：在一条 9 年的样本外路径上，连使用真实 μ 的 Oracle 切点组合都无法在统计上显著胜过 $1/N$ ($p = 0.85$)。这把 DeMiguel et al. (2009) 的结论又推进一步——不仅估计误差会摧毁样本内最优，而且单条路径的噪声之大，使任何“跑赢”都难以被证实。

9 给期望收益开药方：Bayes-Stein 收缩、Black-Litterman 与维数相变

9.1 Jorion 的 Bayes-Stein 收缩

既然实验证明 μ 的估计误差是样本外失败的元凶，经典药方是对 μ 本身做收缩（与 Ledoit-Wolf 对 Σ 的收缩完全对仗）。Jorion (1986) 把样本均值 $\hat{\mu}$ 向 GMV 隐含收益 $\mu_0 = \frac{\mathbf{1}^\top \Sigma^{-1} \hat{\mu}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}$ 收缩：

$$\mu_{\text{BS}} = (1 - \hat{w}) \hat{\mu} + \hat{w} \mu_0 \mathbf{1}, \quad \hat{w} = \frac{n + 2}{(n + 2) + T (\hat{\mu} - \mu_0 \mathbf{1})^\top \Sigma^{-1} (\hat{\mu} - \mu_0 \mathbf{1})} \in (0, 1]. \quad (21)$$

收缩强度由 $\hat{\mu}$ 偏离目标的马氏距离决定：偏离越像噪声（相对于 T 个样本的抽样误差），收缩越狠。实验中 $\hat{w} \in [0.39, 0.81]$ ， μ 的平均估计误差从 0.77 降到 0.49（年化 ℓ_2 范数），切点组合换手率近乎减半。

9.2 Black-Litterman 均衡先验与”无观点定理”

从”市场组合即等权 $w_{\text{eq}} = \mathbf{1}/n$ ”反向优化出均衡隐含收益

$$\pi = r_f \mathbf{1} + \delta \Sigma w_{\text{eq}}, \quad \delta = \frac{\bar{r}_{\text{mkt}} - r_f}{\sigma_{\text{mkt}}^2}. \quad (22)$$

以 π 为输入的切点组合权重为 $w \propto \Sigma^{-1}(\pi - r_f \mathbf{1}) = \delta w_{\text{eq}}$ ，归一化后恰好还原 w_{eq} （ δ 在归一化中消去）——不持有观点的贝叶斯投资者就该持有市场。实验对全部 108 个滚动窗口数值验证： $\max |w_{\text{BL}} - \mathbf{1}/n| \approx 10^{-15}$ （机器精度）。

进一步做收缩路径扫描 $\mu_\varphi = (1 - \varphi)\pi + \varphi \hat{\mu}$ ：最优在 $\varphi^* = 0$ （纯均衡），且中间 φ 并非平滑过渡而是剧烈震荡——当混合后的超额收益向量 $\mu_\varphi - r_f \mathbf{1}$ 接近零向量时，切点归一化因子 $\mathbf{1}^\top \Sigma^{-1}(\mu_\varphi - r_f \mathbf{1})$ 趋零，权重爆炸。在这条样本路径上，样本信息掺入多少都只会伤害组合。

9.3 维数相变：RMT 的翻案

固定 $T = 252$ 、把资产数从 $n = 8$ 扫到 200 ($q = n/T$ 从 0.03 到 0.79)，数据生成过程同构、真实信号秩恒为 4。以 GMV 的样本外实现波动衡量 $\hat{\Sigma}$ 的质量（不经过 μ ）：

q 小时四种估计并列； $q \rightarrow 1$ 时样本协方差条件数爆炸（中位数 $\approx 1.1 \times 10^4$ ），其 GMV 波动回升到与等权持平——**维数带来的分散化红利被估计误差悉数吃掉**；而 MP 裁剪与 PCA 因子估计只保留 $O(1)$ 个信号特征对，对维数免疫，波动持续下降（18% $\rightarrow$ 9%）。与第 8 节合看：RMT 在 q 小时是误伤真实因子的手术刀，在 q 大时是唯一的救命稻草——任何估计量都有其适用边界。

10 结论

本项目以矩阵算法为主线，完整走通了一个量化金融多目标规划问题：从双目标建模、标量化，到拉格朗日/KKT 闭式解（依托 Cholesky 与特征分解）、再到不可卖空约束下从零实现的投影梯度下降（含单纯形投影推导与收敛性分析），最后用 Ledoit–Wolf 收缩把机器学习的正则化思想引入协方差估计。在此基础上，样本外滚动回测量化了 μ 估计误差的真实代价，随机矩阵理论与 block bootstrap 揭示了协方差谱手术的低维局限与回测结论本身的统计不确定性，Bayes–Stein 收缩与 Black–Litterman 均衡先验给出了 μ 的可行药方，维数扫描则画出了每种估计量的适用边界。理论推导、代码实现、图像与数值自检相互印证，可作为矩阵算法课程的完整范例。