

均值-方差投资组合的多目标规划： 矩阵算法、解析解与投影梯度下降

矩阵算法课程项目

2026 年 6 月 10 日

摘要

本项目把量化金融中最经典的资产配置问题——Markowitz 均值-方差模型——建模为一个 **双目标规划问题**（同时最大化期望收益、最小化风险），并从**矩阵算法**的视角给出完整推导与实现。我们：(1) 用拉格朗日乘子法与 KKT 条件导出允许卖空时有效前沿的 **闭式解**，核心是对对称正定协方差矩阵 Σ 的求逆/求解（Cholesky 分解）；(2) 在加入不可卖空约束 $w \geq 0$ 后问题失去闭式解，于是**从零实现投影梯度下降**（含单纯形欧氏投影的 KKT 推导与收敛性分析）；(3) 用 Ledoit-Wolf 收缩估计这一 **统计学习（机器学习）** 方法改善 Σ 的估计，并定量展示其在小样本/高维时的价值。全部结论在合成但统计特征真实的 8 资产数据上验证，并附 5 张图像。

目录

1	问题背景与现实意义	1
2	多目标规划建模	2
2.1	符号与假设	2
2.2	双目标模型	2
2.3	标量化：把多目标化为单目标	2
3	解析解：拉格朗日乘子与 KKT 条件	2
3.1	一阶最优性条件	2
3.2	消去乘子：一个 2×2 线性系统	3
3.3	有效前沿的闭式表达	3
3.4	两个关键组合	3
4	矩阵算法要点	4
4.1	用 Cholesky 分解求解，而非显式求逆	4
4.2	特征分解与条件数	4

1 问题背景与现实意义	2
4.3 正定性 $\Leftrightarrow$ 凸性 $\Rightarrow$ 全局最优	4
5 数值解：投影梯度下降	4
5.1 为什么需要数值法	4
5.2 投影梯度下降 (PGD)	5
5.3 单纯形欧氏投影的推导	5
5.4 收敛性分析	5
6 机器学习联系：协方差矩阵的收缩估计	5
7 实验与结果	6
8 随机矩阵理论与自助法推断 (样本外实验补充)	9
8.1 Marcenko–Pastur 定理与特征值裁剪	9
8.2 Circular block bootstrap 与夏普差检验	9
9 结论	10

1 问题背景与现实意义

设某投资者面对 n 只股票，需决定把资金按比例 $\mathbf{w} = (w_1, \dots, w_n)^\top$ 配置到各资产上 (w_i 为第 i 只股票的权重, $\sum_i w_i = 1$)。投资者的两个目标天然冲突：

- **收益越高越好**：组合期望收益为 $\boldsymbol{\mu}^\top \mathbf{w}$ ，其中 $\boldsymbol{\mu} \in \mathbb{R}^n$ 是各资产期望收益；
- **风险越低越好**：组合方差为 $\mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w}$ ，其中 $\boldsymbol{\Sigma} \in \mathbb{R}^{n \times n}$ 是收益的协方差矩阵。

高收益资产往往伴随高波动，因此不存在同时让两者最优的单一解，而是一族**折中 (Pareto) 解**。寻找这族解、并理解“多承担一单位风险能换来多少额外收益”，正是资产配置的核心，也是一个标准的**多目标规划**问题。其数学骨架完全由矩阵运算构成（二次型、矩阵求逆、特征分解），因此非常适合作为矩阵算法课程的综合案例。

2 多目标规划建模

2.1 符号与假设

记全 1 向量为 $\mathbf{1} \in \mathbb{R}^n$ 。假设 $\boldsymbol{\Sigma}$ **对称正定** ($\boldsymbol{\Sigma} \succ 0$) ——这在样本协方差中当观测期数 $T > n$ 且无完全共线资产时几乎必然成立，也保证了二次型 $\mathbf{w}^\top \boldsymbol{\Sigma} \mathbf{w} > 0$ （任意非零组合都有正风险）以及目标函数的**严格凸性**。

2.2 双目标模型

$$\min_w \left(\mathbf{w}^\top \Sigma \mathbf{w}, -\boldsymbol{\mu}^\top \mathbf{w} \right) \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1, \quad (\text{可选}) \quad \mathbf{w} \geq \mathbf{0}. \quad (1)$$

约束 $\mathbf{1}^\top \mathbf{w} = 1$ 表示资金全部投出； $\mathbf{w} \geq \mathbf{0}$ 表示不可卖空（只能买入）。

定义 1 (Pareto 最优). 可行解 $\mathbf{w}^*$ 称为 Pareto 最优，若不存在另一可行解 $\mathbf{w}$ 使得两个目标都不更差、且至少一个严格更优。所有 Pareto 最优组合在 $(\sigma, r) = (\sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}, \boldsymbol{\mu}^\top \mathbf{w})$ 平面上的像称为**有效前沿** (efficient frontier)。

2.3 标量化：把多目标化为单目标

求解多目标规划的常用手段是**标量化**，即用一个标量参数把两目标合成一个目标，扫描该参数即可得到整条前沿。本文用两种等价方式：

(a) **加权和法**。引入风险偏好系数 $\lambda \geq 0$ ：

$$\min_w \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}^\top \mathbf{w} \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1. \quad (2)$$

$\lambda = 0$ 对应纯最小方差； $\lambda \rightarrow \infty$ 对应纯最大收益。

(b) **ε -约束法**。固定一个目标收益 r ，最小化风险：

$$\min_w \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} \quad \text{s.t.} \quad \boldsymbol{\mu}^\top \mathbf{w} = r, \quad \mathbf{1}^\top \mathbf{w} = 1. \quad (3)$$

扫描 r 即得前沿。由于 $\Sigma \succ 0$ 使目标严格凸、约束为线性，两种标量化都给出唯一全局最优，且其解集相同（KKT 充要）。下一节用 (3) 推导闭式解。

3 解析解：拉格朗日乘子与 KKT 条件

3.1 一阶最优性条件

对 (3) 写拉格朗日函数 (λ, γ 为乘子)：

$$\mathcal{L}(\mathbf{w}, \lambda, \gamma) = \frac{1}{2} \mathbf{w}^\top \Sigma \mathbf{w} - \lambda(\boldsymbol{\mu}^\top \mathbf{w} - r) - \gamma(\mathbf{1}^\top \mathbf{w} - 1). \quad (4)$$

对 $\mathbf{w}$ 求梯度并令其为零（这就是等式约束下的 KKT 平稳性条件）：

$$\nabla_{\mathbf{w}} \mathcal{L} = \Sigma \mathbf{w} - \lambda \boldsymbol{\mu} - \gamma \mathbf{1} = \mathbf{0} \implies \boxed{\mathbf{w} = \Sigma^{-1}(\lambda \boldsymbol{\mu} + \gamma \mathbf{1})}. \quad (5)$$

因目标严格凸、约束线性，该平稳点即**全局最优**。

3.2 消去乘子：一个 2×2 线性系统

把 (5) 代入两个约束，并定义四个由矩阵 Σ 决定的标量

$$A = \mathbf{1}^\top \Sigma^{-1} \boldsymbol{\mu}, \quad B = \boldsymbol{\mu}^\top \Sigma^{-1} \boldsymbol{\mu}, \quad C = \mathbf{1}^\top \Sigma^{-1} \mathbf{1}, \quad D = BC - A^2, \quad (6)$$

得到

$$\begin{cases} \boldsymbol{\mu}^\top \mathbf{w} = \lambda B + \gamma A = r, \\ \mathbf{1}^\top \mathbf{w} = \lambda A + \gamma C = 1, \end{cases} \iff \begin{bmatrix} B & A \\ A & C \end{bmatrix} \begin{bmatrix} \lambda \\ \gamma \end{bmatrix} = \begin{bmatrix} r \\ 1 \end{bmatrix}. \quad (7)$$

该系数矩阵的行列式恰为 $D = BC - A^2$ 。由 Cauchy-Schwarz 不等式（在内积 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \Sigma^{-1} \mathbf{y}$ 下）可证 $D > 0$ （当 $\boldsymbol{\mu}$ 与 $\mathbf{1}$ 线性无关），故系统可解：

$$\lambda = \frac{Cr - A}{D}, \quad \gamma = \frac{B - Ar}{D}. \quad (8)$$

3.3 有效前沿的闭式表达

最优组合的方差可由 (5) 巧妙化简（利用 $\mathbf{w}^\top \Sigma \mathbf{w} = \mathbf{w}^\top (\lambda \boldsymbol{\mu} + \gamma \mathbf{1}) = \lambda r + \gamma$ ）：

$$\boxed{\sigma^2(r) = \mathbf{w}^\top \Sigma \mathbf{w} = \frac{Cr^2 - 2Ar + B}{D}}. \quad (9)$$

这是 (σ^2, r) 平面上的**抛物线**、 (σ, r) 平面上的**双曲线**——即图1 中的有效前沿。其顶点（最小方差点）由 $d\sigma^2/dr = 0$ 给出。

3.4 两个关键组合

命题 1 (全局最小方差组合 GMV). 在 (3) 中去掉收益约束，只留 $\mathbf{1}^\top \mathbf{w} = 1$ ，解得

$$\mathbf{w}_{\text{gmv}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} = \frac{\Sigma^{-1} \mathbf{1}}{C}, \quad \sigma_{\text{gmv}}^2 = \frac{1}{C}, \quad r_{\text{gmv}} = \frac{A}{C}. \quad (10)$$

证明. 由 $\Sigma \mathbf{w} = \gamma \mathbf{1}$ 得 $\mathbf{w} = \gamma \Sigma^{-1} \mathbf{1}$ ；代入 $\mathbf{1}^\top \mathbf{w} = 1$ 得 $\gamma = 1/C$ 。方差 $\mathbf{w}^\top \Sigma \mathbf{w} = \gamma^2 \mathbf{1}^\top \Sigma^{-1} \mathbf{1} = C/C^2 = 1/C$ 。□

项目中以 $\sigma_{\text{gmv}}^2 = 1/C$ 作为**数值自检**：闭式公式与 $\mathbf{w}_{\text{gmv}}^\top \Sigma \mathbf{w}_{\text{gmv}}$ 的误差为 0（机器精度）。

命题 2 (切点/最大夏普组合). 设无风险收益为 r_f 。在可投资无风险资产时，使夏普比 $S(\mathbf{w}) = (\boldsymbol{\mu}^\top \mathbf{w} - r_f) / \sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}$ 最大的组合为

$$\mathbf{w}_{\text{tan}} = \frac{\Sigma^{-1}(\boldsymbol{\mu} - r_f \mathbf{1})}{\mathbf{1}^\top \Sigma^{-1}(\boldsymbol{\mu} - r_f \mathbf{1})}. \quad (11)$$

过点 $(0, r_f)$ 与切点 $(\sigma_{\text{tan}}, r_{\text{tan}})$ 的直线即 **资本市场线 (CML)**，其斜率等于最大夏普比，见图1。

定理 1 (两基金分离定理). 由 (5)–(8)，前沿上任意组合 $\mathbf{w}(r) = \lambda(r) \Sigma^{-1} \boldsymbol{\mu} + \gamma(r) \Sigma^{-1} \mathbf{1}$ 都是两支固定基金 $\Sigma^{-1} \boldsymbol{\mu}$ 与 $\Sigma^{-1} \mathbf{1}$ 的线性组合，且组合系数关于 r 仿射。因此只需两支前沿基金即可张成整条前沿。

4 矩阵算法要点

4.1 用 Cholesky 分解求解，而非显式求逆

上述闭式解需要 $\Sigma^{-1}\mu$ 与 $\Sigma^{-1}\mathbf{1}$ 。直接计算 Σ^{-1} 代价高且数值不稳。由于 $\Sigma \succ 0$ ，存在唯一下三角 L 使

$$\Sigma = LL^T \quad (\text{Cholesky 分解}). \quad (12)$$

于是解 $\Sigma x = b$ 化为两步三角求解：前代解 $Ly = b$ ，回代解 $L^T x = y$ 。本项目在 `analytic.py` 中手写前代/回代以体现该矩阵算法。其复杂度 $O(n^3/3)$ 优于通用求逆，且条件数更友好。

4.2 特征分解与条件数

对称正定阵可正交对角化 $\Sigma = Q\Lambda Q^T$ ，特征值 $\lambda_1 \geq \dots \geq \lambda_n > 0$ 。**条件数** $\kappa(\Sigma) = \lambda_1/\lambda_n$ 衡量求解的数值稳定性；它也决定了第 5 节投影梯度下降的收敛速度。特征向量则可解释为**风险主成分**（最大特征值方向即市场系统性风险方向）。

4.3 正定性 $\Leftrightarrow$ 凸性 $\Rightarrow$ 全局最优

目标 $f(w) = \frac{1}{2}w^T \Sigma w - \lambda \mu^T w$ 的 Hessian 为 $\nabla^2 f = \Sigma$ 。 $\Sigma \succ 0$ 即 f **严格凸**，故任何满足 KKT 的平稳点都是唯一全局最优——这正是上一节闭式解全局最优的理论依据。

5 数值解：投影梯度下降

5.1 为什么需要数值法

加入不可卖空约束后，问题变为带不等式的二次规划

$$\min_w \frac{1}{2} w^T \Sigma w - \lambda \mu^T w \quad \text{s.t.} \quad \mathbf{1}^T w = 1, \quad w \geq 0. \quad (13)$$

可行域是**概率单纯形** $\Delta = \{w : w \geq 0, \mathbf{1}^T w = 1\}$ 。不等式约束使乘子需满足互补松弛，一般没有闭式解，须迭代求解。

5.2 投影梯度下降 (PGD)

PGD 交替执行“沿负梯度走一步”与“投影回可行域”：

$$w_{k+1} = \text{Proj}_\Delta(w_k - \eta \nabla f(w_k)), \quad \nabla f(w) = \Sigma w - \lambda \mu. \quad (14)$$

5.3 单纯形欧氏投影的推导

投影本身是一个子优化问题：

$$\text{Proj}_\Delta(\mathbf{v}) = \arg \min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w} - \mathbf{v}\|^2 \quad \text{s.t.} \quad \mathbf{1}^\top \mathbf{w} = 1, \mathbf{w} \geq \mathbf{0}. \quad (15)$$

写 KKT (乘子 $\tau \in \mathbb{R}$ 对应等式, $\beta \geq \mathbf{0}$ 对应 $\mathbf{w} \geq \mathbf{0}$):

$$(w_i - v_i) + \tau - \beta_i = 0, \quad \beta_i \geq 0, \quad w_i \geq 0, \quad \beta_i w_i = 0.$$

由互补松弛：若 $w_i > 0$ 则 $\beta_i = 0$, 得 $w_i = v_i - \tau$; 若 $w_i = 0$ 则需 $v_i \leq \tau$ 。合并：

$$\boxed{w_i = \max(v_i - \tau, 0)}, \quad \tau \text{ 由 } \sum_i \max(v_i - \tau, 0) = 1 \text{ 唯一确定}. \quad (16)$$

求阈值 τ 的高效算法 (排序法)：将 $\mathbf{v}$ 降序排成 $u_1 \geq \dots \geq u_n$, 令

$$\rho = \max \left\{ j : u_j - \frac{1}{j} \left(\sum_{i \leq j} u_i - 1 \right) > 0 \right\}, \quad \tau = \frac{1}{\rho} \left(\sum_{i \leq \rho} u_i - 1 \right), \quad (17)$$

复杂度 $O(n \log n)$ 。该算法在 `numeric.py` 的 `project_to_simplex` 中实现。

5.4 收敛性分析

f 的梯度 $\nabla f(\mathbf{w}) = \Sigma \mathbf{w} - \lambda \boldsymbol{\mu}$ 关于 $\mathbf{w}$ 是**利普希茨连续**的, 常数 $L = \lambda_{\max}(\Sigma)$; 同时 f 以 $m = \lambda_{\min}(\Sigma) > 0$ **强凸**。取步长 $\eta = 1/L$, 标准结果给出：

- 仅用凸性： $f(\mathbf{w}_k) - f^* \leq \frac{L \|\mathbf{w}_0 - \mathbf{w}^*\|^2}{2k} = O(1/k)$;
- 利用强凸 (本问题 $\Sigma \succ 0$)：**线性 (几何) 收敛** $\|\mathbf{w}_k - \mathbf{w}^*\|^2 \leq \left(1 - \frac{m}{L}\right)^k \|\mathbf{w}_0 - \mathbf{w}^*\|^2$, 速率由条件数 $\kappa = L/m$ 决定。

图3 (左) 中 $f(\mathbf{w}_k) - f^*$ 在对数轴上近似直线下降, 正是**线性收敛**的体现, 与强凸理论一致。

6 机器学习联系：协方差矩阵的收缩估计

实践中 $\boldsymbol{\mu}, \Sigma$ 未知, 须从历史收益估计。样本协方差 $\mathbf{S}$ 虽无偏, 但在 **维数高 / 样本少** 时方差大、接近奇异 (条件数巨大), 导致 Σ^{-1} 放大噪声、优化权重极端不稳。**Ledoit-Wolf 收缩估计** 是一种统计学习 (正则化) 方法, 把 $\mathbf{S}$ 向结构化目标 $\mathbf{F} = m\mathbf{I}$ ($m = \text{tr}(\mathbf{S})/n$ 为平均方差) 收缩：

$$\Sigma_{\text{LW}} = \delta (m\mathbf{I}) + (1 - \delta) \mathbf{S}, \quad \delta \in [0, 1]. \quad (18)$$

最优收缩强度 δ^* 由最小化期望误差 $\mathbb{E} \|\Sigma_{\text{LW}} - \Sigma_{\text{true}}\|^2$ 解析给出 (见 `data_utils.py`), 本质是**偏差-方差权衡**： $\mathbf{S}$ 无偏但高方差, $m\mathbf{I}$ 有偏但低方差, δ^* 自动折中。图4 (右) 定量显示：样本越少, $\mathbf{S}$ 的条件数越爆炸, 而 Σ_{LW} 始终良态——这正是“机器学习改善估计”在本问题中的体现。

7 实验与结果

数据为合成的 8 只股票（科技/金融/消费三行业）、约 3 年日收益率，用三因子模型生成，保留真实的行业块状相关结构（图4 左）。全流程口径年化，无风险利率取 $r_f = 3\%$ 。




图 1: 均值-方差有效前沿（解析，允许卖空）。红星为 GMV，绿菱为切点组合，虚线为资本市场线（斜率=最大夏普比）。




图 2: 可行域、单资产与前沿。散点为随机长仓组合（按夏普比着色），三角为单只股票。单资产均位于前沿内侧，说明**分散化**可在同等收益下显著降低风险。




图 3: 左: 投影梯度下降的目标值误差 $f(w_k) - f^*$ (对数轴, 呈线性收敛)。右: 长仓 ($w \geq 0$) 数值前沿位于允许卖空的解析前沿内侧, 高收益端差距明显, 说明不可卖空约束牺牲了一部分可达收益。




图 4: 左: 相关系数矩阵, 行业内相关明显高于行业间 (块状结构)。右: 条件数随估计窗口长度 T 的变化——样本越少, 样本协方差越病态, 而 Ledoit-Wolf 收缩始终保持良态。




图 5: 三种代表性组合的资产权重。切点组合 (允许卖空) 出现明显负权重 (做空低收益资产), 而长仓最小方差组合全部非负——直观展示约束 $w \geq 0$ 的影响。

结果解读。 GMV 把资金集中到低波动的金融/消费股, 年化波动最低; 切点组合通过做空低收益资产、做多高夏普资产取得最高夏普比; 加入不可卖空约束后, 前沿整体内移、可达收益上限下降。所有解析结论均通过数值自检 ($\sigma_{\text{gmV}}^2 = 1/C$ 、权重和为 1、KKT 残差 ≈ 0 、自研 PGD 与 `scipy` 的 SLSQP 解最大偏差 $< 10^{-3}$), 见 `results/summary.json`。

8 随机矩阵理论与自助法推断（样本外实验补充）

8.1 Marchenko–Pastur 定理与特征值裁剪

设 $T \times n$ 数据矩阵的行向量为 i.i.d. 纯噪声（方差 σ^2 ）。当 $T, n \rightarrow \infty$ 、 $q = n/T$ 固定时，样本相关矩阵的特征值依分布收敛到 Marchenko–Pastur 律

$$\rho(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi q \sigma^2 \lambda}, \quad \lambda_{\pm} = \sigma^2(1 \pm \sqrt{q})^2, \quad (19)$$

支撑为 $[\lambda_-, \lambda_+]$ 。于是凡落入噪声带的样本特征值与纯噪声在统计上不可区分，只有 $\lambda > \lambda_+$ 的特征值才携带真实相关结构（市场/行业因子）。

裁剪估计量（Bouchaud–Potters 配方）。 对样本相关阵作特征分解 $C = V\Lambda V^T$ ，把 $\lambda_i \leq \lambda_+$ 的噪声特征值替换为它们的均值（**保迹**： $\sum_i \lambda'_i = \text{tr } C = n$ ），重构 $C' = V\Lambda'V^T$ 后重新归一使对角恰为 1，再乘回样本标准差得 Σ_{RMT} 。

因子估计量。 只保留 $k = \#\{\lambda_i > \lambda_+\}$ 个信号特征对：

$$C_f = \sum_{i \leq k} \lambda_i v_i v_i^T + D, \quad D_{jj} = 1 - \sum_{i \leq k} \lambda_i v_{ij}^2 = \sum_{i > k} \lambda_i v_{ij}^2 \geq 0, \quad (20)$$

对角残差使 C_f 半正定且对角为 1。由迹约束知平均特征值为 $1 < \lambda_+$ ，故必有 $k < n$ （全部特征值超界将使迹超过 $n\lambda_+ > n$ ，矛盾）。

低维警示。 本项目 $q = 8/252 \approx 0.032$ ， $\lambda_+ \approx 1.39$ ，噪声带很窄。实验中全部 108 个滚动窗口都只有市场因子（ $\lambda \approx 3 \sim 4$ ）超出 λ_+ ，三个行业因子在统计上与噪声不可分而被一并裁掉——裁剪后的 Σ 低估行业内相关，反而令切点组合的杠杆更极端（样本外夏普 -0.56 ，劣于直接用样本协方差）。RMT 是 n/T 较大时的高维武器；低维时样本协方差本不病态，谱手术的收益预期有限，甚至为负。

8.2 Circular block bootstrap 与夏普差检验

单条样本外收益路径给出的夏普比率只是点估计。设 m 个策略的样本外日收益矩阵为 $R \in \mathbb{R}^{T \times m}$ ，第 b 次重采样以块长 ℓ （取再平衡周期 21 天）生成环形块索引：块起点独立同分布于 $U\{0, \dots, T-1\}$ ，每块取连续 ℓ 天（模 T 回绕），拼接后截断到长度 T ——块内的波动聚集等时序依赖得以保留。

关键设计是**联合重采**：同一组索引同时作用于 R 的全部 m 列，保留策略间的截面相关。如此夏普差 $\Delta_b = \widehat{\text{SR}}_b^{(i)} - \widehat{\text{SR}}_b^{(j)}$ 中共同的市场波动相互抵消，检验才有功效；若各列独立重采， Δ 的方差将被严重高估。每个 resample 内**整段重算**年化夏普（均值与波动在同一 resample 内相关，不可分别抽样再组合）。双侧 p 值采用 $(\# + 1)/(B + 1)$ 修正以避免报出 $p = 0$ 。

实验结论。 $B = 2000$ 次重采样下，全部策略相对等权 $1/N$ 的 ΔSharpe 置信区间均横跨 0（最小 $p = 0.079$ ）：在一条 9 年的样本外路径上，连使用真实 μ 的 Oracle 切点组合都无法在统计上显著胜过 $1/N$ ($p = 0.85$)。这把 DeMiguel et al. (2009) 的结论又推进一步——不仅估计误差会摧毁样本内最优，而且单条路径的噪声之大，使任何“跑赢”都难以被证实。

9 结论

本项目以矩阵算法为主线，完整走通了一个量化金融多目标规划问题：从双目标建模、标量化，到拉格朗日/KKT 闭式解（依托 Cholesky 与特征分解）、再到不可卖空约束下从零实现的投影梯度下降（含单纯形投影推导与收敛性分析），最后用 Ledoit–Wolf 收缩把机器学习的正则化思想引入协方差估计。在此基础上，样本外滚动回测量化了 μ 估计误差的真实代价，随机矩阵理论与 block bootstrap 进一步揭示了协方差谱手术的低维局限与回测结论本身的统计不确定性。理论推导、代码实现、图像与数值自检相互印证，可作为矩阵算法课程的完整范例。